

Đề tài học phần mở rộng

Rút gọn tập ảnh lớn bằng phát hiện ảnh trùng nội dung dựa trên học sâu và băm đặc trưng

Lớp Kỹ sư Tài năng – Cấu trúc dữ liệu và Giải thuật

1 Mục tiêu

Xây dựng một hệ thống giúp phát hiện và loại bỏ các ảnh trùng lặp hoặc gần giống nhau trong một tập dữ liệu ảnh lớn. Sinh viên cần nghiên cứu và áp dụng các kỹ thuật học sâu để trích xuất đặc trưng nội dung ảnh. Việc trích đặc trưng được xem như một *hàm ánh xạ*: đầu vào là ảnh, đầu ra là vector.

Sau đó, sinh viên sẽ tìm hiểu và triển khai các kỹ thuật băm như **Hash Table**, **Bloom Filter**, **SimHash**, **MinHash**, kết hợp với thư viện **FAISS** để thực hiện tìm kiếm ảnh tương tự một cách hiệu quả. Mục tiêu là đánh giá và so sánh hiệu quả giữa các phương pháp băm tự xây dựng và giải pháp FAISS trên tập dữ liệu ảnh thực tế.

2 Yêu cầu chính

- Nghiên cứu lý thuyết:** Trình bày tổng quan các kỹ thuật băm đặc trưng (**Hash Table**, **Bloom Filter**, **SimHash**, **MinHash**) và thư viện **FAISS** (mục tiêu, cách hoạt động, ưu điểm – hạn chế).
- Xây dựng hệ thống:**
 - Trích xuất đặc trưng nội dung ảnh bằng mô hình học sâu sẵn có (ví dụ: *ResNet*, *EfficientNet*) thông qua thư viện như `timm`, `torchvision`.
 - Ánh xạ đặc trưng thành vector và áp dụng một hoặc nhiều kỹ thuật băm đã tìm hiểu (tự cài đặt nếu có thể).
 - Dùng FAISS hoặc thư viện tương tự để tìm kiếm ảnh gần giống trong không gian đặc trưng.
- So sánh và đánh giá:**
 - So sánh kết quả và hiệu năng giữa các phương pháp băm đặc trưng tự xây dựng và FAISS (về độ chính xác, tốc độ, bộ nhớ).
 - Phân tích ưu – nhược điểm của từng phương pháp.
- Lựa chọn ảnh đại diện:** Mỗi nhóm ảnh trùng lặp hoặc gần giống cần chọn ra một ảnh đại diện duy nhất (theo tiêu chí rõ ràng như độ phân giải, độ nét, kích thước...).
- Ngôn ngữ lập trình:** Ưu tiên hiện thực bằng **C++** và bind sang Python nếu có kỹ năng. Nếu không, có thể dùng toàn bộ **Python**.

3 Kết quả đầu ra

1. Tập ảnh sau xử lý:

- Bộ ảnh đã loại bỏ ảnh trùng hoặc gần giống, mỗi nhóm chỉ giữ 1 ảnh đại diện.

2. Thống kê cụm ảnh:

- Số ảnh ban đầu, số ảnh sau lọc trùng.
- Số nhóm phát hiện trùng.
- Danh sách tên ảnh từng nhóm và ảnh đại diện.

3. Báo cáo hiệu năng:

- Độ chính xác (precision/recall nếu có ground-truth hoặc đánh giá thủ công).
- Thời gian xử lý từng phương pháp.
- Dung lượng bộ nhớ sử dụng (nếu đo được).
- Bảng so sánh + nhận xét ưu/nhược điểm.

4. Trực quan hóa kết quả:

- Hiển thị một số nhóm ảnh trùng theo bảng (mỗi hàng là 1 nhóm).
- Đánh dấu ảnh đại diện và ảnh bị loại.
- Cho phép đánh giá trực tiếp bằng quan sát.

5. Checklist đánh giá:

- Có ít nhất 3 phương pháp được thử nghiệm (SimHash, MinHash, FAISS).
- Có trực quan hóa kết quả bằng ảnh.
- Có đo thời gian và độ chính xác tương đối.

4 Hình thức báo cáo

1. **Báo cáo kỹ thuật:** Viết theo mẫu $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$, nộp bản PDF cuối kỳ, trình bày rõ ràng các phần: mục tiêu, phương pháp, kết quả, đánh giá.

2. **Mã nguồn:**

- Đưa toàn bộ source code lên GitHub.
- Có README.md mô tả bài toán và hướng dẫn chạy.
- Có hướng dẫn cài đặt thư viện/phụ thuộc.
- **Yêu cầu bắt buộc:** Code phải chạy được trên **Google Colab** (dù viết bằng Python hay C++). Nếu dùng C++, cần có hướng dẫn biên dịch hoặc sử dụng magic commands.
- **Chèn link GitHub và link Google Colab** rõ ràng ở phần đầu báo cáo PDF.

3. **Video demo:** Trình bày kết quả, quy trình xử lý, đầu vào – đầu ra. Thời lượng: 5–10 phút.
4. **Hạn nộp:** Toàn bộ báo cáo + liên kết GitHub + Colab phải được hoàn thành và nộp trước ngày **XX/YY/2025** (thông báo sau).